

JUNGLE IN ENGLISH

Plateforme d'apprentissage de l'anglais propulsée par le Machine Learning

Prédiction de la réussite étudiante | Segmentation | Recommandation de cours

Kenza Baccar Ismail Ismail Khalil Abdelmoumen Nadhem Hmida Mohamed Aziz Louati

SOMMAIRE

9 chapitres

- 01 Introduction générale
- 02 Problématique
- 03 Étude et critique de l'existant
- 04 Solution proposée
- 05 Objectifs métier et data science
- 06 Phase de préparation
- 07 Phase de modélisation
- 08 Déploiement
- 09 Conclusion



01

INTRODUCTION GÉNÉRALE

Contexte et enjeux de l'apprentissage de l'anglais en ligne

Contexte de l'étude

L'anglais est devenu une compétence **indispensable** dans le monde professionnel et académique.

En Tunisie, la demande pour l'apprentissage de l'anglais est en **forte croissance**, mais les solutions traditionnelles peinent à répondre aux besoins des apprenants modernes.

Les plateformes d'apprentissage en ligne génèrent une quantité **massive de données comportementales** : clics, sessions, scores, temps de connexion...

L'analyse de ces données ouvre la voie à la **personnalisation pédagogique** via le Machine Learning.

Dataset utilisé : Open University Learning Analytics Dataset (OULAD)

- 32 593 étudiants
- 7 modules de cours
- 10 655 280 interactions VLE
- 173 912 évaluations

Dataset OULAD – Vue d'ensemble



32 593 étudiants



7 modules de cours



10.6M interactions VLE



173 912 évaluations



7 tables de données

02

PROBLÉMATIQUE

Les défis majeurs de l'apprentissage de l'anglais en ligne

Problématique identifiée



Manque de pratique

Absence d'environnement immersif pour pratiquer l'anglais au quotidien. Les apprenants manquent d'opportunités de conversation réelle.



Coût et complexité

Institutions coûteuses et méthodes d'enseignement inadaptées. Les cours traditionnels sont souvent hors de portée financière.



Manque de temps

Horaires fixes incompatibles avec les emplois du temps chargés. Les apprenants modernes ont besoin de flexibilité.

Défis spécifiques à l'apprentissage en ligne

50%

Taux de décrochage dans l'enseignement en ligne

One-size

Approche "one-size-fits-all" inefficace

Guidage

Difficulté à guider vers les modules pertinents

Local

Manque d'adaptation au contexte local (Tunisie)

03

ÉTUDE ET CRITIQUE DE L'EXISTANT

Analyse des solutions actuelles et leurs limites

Solutions existantes et leurs limites

Solution	Avantages	Limites
Applications mobiles Duolingo, Babbel...	Ludique, gratuit, accessible	Manque de pratique orale réelle
Plateformes en ligne Udemy, Coursera...	Cours variés, experts reconnus	Contenu trop théorique, peu de personnalisation
Centres de langues Présentiel	Formation encadrée, interaction humaine	Prix élevés, manque de suivi digital
Contenus gratuits YouTube, blogs...	Accessibles à tous, gratuit	Non adapté au contexte local, manque de motivation

Limites communes identifiées

- ❌ Manque de pratique orale réelle
- ❌ Peu de personnalisation
- ❌ Manque de suivi et motivation
- ❌ Non adapté au contexte local

A dense, lush green jungle scene with various tropical plants, including large leaves and ferns, creating a vibrant and naturalistic background.

04

SOLUTION PROPOSÉE

Jungle in English — Une plateforme interactive et personnalisée

Jungle in English – Concept et fonctionnalités

Concept : Plateforme en ligne pour apprendre l'anglais de façon **interactive, pratique et motivante**, adaptée aux jeunes.

Fonctionnalités clés

- Cours d'anglais simples et progressifs
- Exercices interactifs
- Sessions de conversation en direct
- Suivi du progrès personnalisé
- Clubs d'anglais pour apprendre en s'amusant
- Forum interactif étudiant-étudiant
- Messagerie entre étudiants et professeurs

Valeur ajoutée



Apprentissage pratique + communication réelle



Interaction sociale (clubs, forum, messagerie)



Expérience motivante et engageante



Prix abordable et accessible partout en ligne

Objectif : Aider les utilisateurs à apprendre, pratiquer et communiquer en anglais, tout en restant motivés grâce à une **expérience interactive**.

05

OBJECTIFS MÉTIER ET DATA SCIENCE

Alignement stratégique entre besoins métier et solutions ML

Objectifs métier et objectifs data science

Objectifs métier

- 1 Réduire le décrochage**
Identifier précocement les étudiants à risque pour déclencher des interventions ciblées (tutorat, accompagnement).
- 2 Identifier les profils**
Segmenter les étudiants en profils distincts pour personnaliser les parcours pédagogiques et les ressources proposées.
- 3 Améliorer l'engagement**
Recommander des modules adaptés aux profils et aux parcours pour maximiser l'engagement et la réussite.

Objectifs data science

1. Segmentation (Clustering)

Techniques : K-Means, Agglomerative, DBSCAN

Métriques : Silhouette Score, Davies-Bouldin Index

2. Classification (Prédiction)


Techniques : Logistic Regression, Random Forest, XGBoost

Métriques : Accuracy, F1-Score, ROC-AUC, Matrice de Confusion

3. Recommandation

Techniques : Cosine Similarity, SVD

Métriques : RMSE, Similarité entre items



06

PHASE DE PRÉPARATION

De l'exploration à la construction des datasets finaux

Préparation des données – EDA et Feature Engineering

Dataset OULAD : 7 tables interconnectées

- **assessments** – 206 évaluations
- **courses** – 22 présentations de modules
- **studentAssessment** – 173 912 résultats
- **studentInfo** – 32 593 profils étudiants
- **studentRegistration** – 32 593 inscriptions
- **studentVle** – 10 655 280 interactions
- **vle** – 6 364 ressources pédagogiques

3 Datasets finaux construits



df_clustering (32 593 × 26)

Segmentation – Clustering non supervisé



df_prediction (32 593 × 28)

Prédiction réussite/échec – Classification supervisée



df_recommandation (103 392 × 8)

Suggestion de modules – Filtrage collaboratif

Pipeline de préparation




Prétraitement appliqué : Encodage des variables catégorielles → StandardScaler (normalisation) → PCA réduction de dimension (12 composantes pour 80% de variance)

Nettoyage : Imputation par médiane/mode, création de features binaires, gestion des valeurs manquantes

07

PHASE DE MODÉLISATION

Entraînement, évaluation et benchmarking des modèles ML



Modélisation – Clustering (Segmentation)

Modèle	Clusters	Silhouette ↑	Davies-Bouldin ↓
K-Means	3	0.1738	1.9506
Agglomerative	3	0.1375	2.2596
DBSCAN	9	0.1833	1.6160

Profils identifiés (K-Means, k=3)

Cluster 0 – Excellents

Très engagés (~3200 clics), notes élevées (~78/100)

→ Proposer certifications avancées

Cluster 1 – Réguliers

Engagement correct (~700 clics), notes correctes (~72/100)

→ Maintenir la motivation

Cluster 2 – Décrocheurs

Peu actifs (~68 clics), notes très faibles (~3.5/100)

→ Déclencher alertes et tutorat

Modèle retenu : K-Means (k=3) – Meilleur Silhouette Score, rapide, scalable, résultats métier interprétables. 3 profils clairement distincts avec des actions pédagogiques spécifiques.

Modélisation – Prédiction (Classification)

Modèle	Accuracy	F1-Score	ROC-AUC
Logistic Regression	0.9044	0.9027	0.9631
Random Forest	0.9371	0.9351	0.9828
XGBoost	0.9376	0.9354	0.9832

Variable cible : target (1=Réussite, 0=Échec)
Distribution : 52.8% échec | 47.2% réussite

Interprétation des résultats

91-96%

Précision quand le modèle prédit une réussite

92-96%

Rappel – étudiants en échec capturés

-0.98

ROC-AUC – Excellente séparation des classes

Facteurs les plus prédictifs

- 1. Engagement (total_clicks, nb_sessions)
- 2. Performance initiale (avg_score, nb_assessments)
- 3. Charge de travail (studied_credits)

Modèle retenu : Random Forest
Meilleur équilibre performance/interprétabilité, robuste aux outliers. ROC-AUC -0.98.


Modélisation – Recommandation (Filtrage collaboratif)

Modèle	Approche	RMSE ↓	Avantage
Cosine Similarity	Item-Based CF	N/A	Simple, interprétable
SVD	Latent Factor	0.4201	Gère la sparsité

Matrice User-Item : 26 074 étudiants × 7 modules

Problème : Sparsité élevée (étudiants inscrits à 1 module/semestre)

Insights clés de similarité



Exemple de recommandation

Pour l'étudiant 6516 (module AAA) :

- 1. FFF – Score SVD : 0.0009
- 2. GGG – Score SVD : 0.0000
- 3. BBB – Score SVD : -0.0000

Modules similaires à AAA :

FFF (similarité : 0.0013)

BBB (similarité : 0.0000)

Modèle retenu : SVD – Mieux adapté à la sparsité, généralise davantage les patterns latents d'inscription. RMSE = 0.4201.

08

DÉPLOIEMENT

Dashboard interactif Streamlit pour l'exploitation des modèles

dreamstime

AI

Dashboard Streamlit – Exploitation des modèles

Technologie : Streamlit – Framework Python open-source pour applications data interactives | Plotly pour les visualisations | Caching pour les performances

Architecture du dashboard



Accueil

État des modèles et guide d'utilisation



Vue d'ensemble

Performances globales et comparaison des modèles



Clustering

Segments, distribution, visualisation PCA 2D



Prédiction

Rapport de classification, matrice de confusion, ROC



Recommandation

Cours recommandés selon profil

Fonctionnalités clés du dashboard



Prédiction temps réel

Succès/échec avec probabilités



Recommandations personnalisées

Par profil et par historique



Visualisations interactives

Plotly avec filtres dynamiques



Jauge de confiance

Indicateur visuel des prédictions



Test interactif

Données personnalisées des étudiants



Rechargement à chaud

Mise à jour des modèles sans redémarrage

CONCLUSION

Ce projet démontre la **valeur ajoutée du Machine Learning** dans l'éducation en ligne.

Trois modèles ML opérationnels :

- **Segmentation** (K-Means) — Profils métier interprétables
 - **Prédiction** (Random Forest) — ROC-AUC -0.98
 - **Recommandation** (SVD) — Gestion de la sparsité

Perspectives : Intégration dans Jungle in English | Déploiement cloud | Feedback loop

Merci pour votre attention

Questions ?